



Prédire un match de foot avant le coup d'envoi ?

J'ai comparé 3 modèles de machine learning sur 1 900 matchs de Premier League — sans jamais tricher avec les stats du match.

Python + scikit-learn

Données Premier League

ce que prédit (vraiment) la data →



Prédire sans tricher avec le futur.

Le piège — la fuite de données

Utiliser les tirs ou les buts du match pour prédire son résultat, c'est tricher : ces chiffres n'existent qu'une fois le match joué.

La parade — la forme récente

Toutes les variables sont calculées sur les 5 derniers matchs de chaque équipe (buts, tirs cadrés, points...), donc connues AVANT le coup d'envoi.
21 variables, zéro fuite.

Un modèle honnête se teste sur le futur, jamais sur des infos qu'il n'aurait pas le jour du match.



Random Forest l'emporte de justesse.




60% de bons pronostics, contre 57% pour un réflexe naïf.

Mieux que le hasard, mais le football garde sa part d'imprévu — et c'est tant mieux. Un penalty, un carton rouge... restent imprévisibles.




C'est l'écart de forme qui parle.



Le modèle a appris seul que la DIFFÉRENCE de dynamique entre les deux équipes (écart de points et de buts récents) pèse plus que la forme d'une seule équipe prise isolément.



La data dessine 4 styles d'équipes.



Sans jamais lui donner le classement, un KMeans regroupe les équipes en 4 familles cohérentes — des cadors aux équipes qui luttent pour le maintien. Preuve que les données portent une vraie structure.



Une démarche, pas une boule de cristal.

- Une seule ligue, 5 saisons : à généraliser avec prudence.
- Blessures, fatigue, compositions... ignorées faute de données.
- AUC $\sim 0,65$: un résultat honnête, pas un système de paris.

Ce que ce projet démontre

Une chaîne complète et reproductible : données réelles, features sans fuite, comparaison de modèles, clustering, et un modèle exporté prêt à prédire de nouveaux matches.

Le code + le rapport complet sont dispos. On en parle ? →