

Prédire le résultat d'un match de football

Machine learning supervisé & non supervisé — Premier League

Le défi. Peut-on, **avant le coup d'envoi**, estimer la probabilité qu'une équipe gagne à domicile, en se basant uniquement sur la dynamique récente des deux équipes ? J'ai comparé deux modèles supervisés (régression logistique et random forest) et exploré les styles de jeu via un modèle non supervisé (KMeans), sur **1900 matchs** de Premier League (5 saisons).

1900

matchs analysés

21

variables pré-match

64%

AUC (meilleur modèle)

3

modèles comparés

Données : football-data.co.uk (Premier League, E0). Stack : Python, pandas, scikit-learn, matplotlib, ReportLab. Code et modèle exporté fournis avec ce rapport.

1. La démarche

Cible. Une variable binaire : l'équipe à domicile gagne (1) ou non — nul ou défaite (0). Sur la période, le domicile l'emporte dans **43%** des cas, ce qui fixe la barre à battre : un modèle qui prédirait systématiquement la classe majoritaire atteindrait déjà **57%** de bonnes réponses. Tout l'enjeu est de faire mieux que ce réflexe.


Le piège évité : la fuite de données. Il serait tentant d'utiliser les tirs, corners ou buts du match pour prédire son résultat. Mais ces statistiques ne sont connues qu'*après* le match : les utiliser donnerait un modèle brillant en apparence mais **inutilisable en conditions réelles**. J'ai donc construit des variables uniquement à partir de la **forme récente** de chaque équipe (moyennes sur ses 5 derniers matchs : buts, tirs cadrés, points, etc.), toutes disponibles avant le coup d'envoi.

Validation honnête. Séparation chronologique train/test (on entraîne sur le passé, on teste sur les matchs les plus récents) et validation croisée à 5 plis. On ne triche jamais avec le futur.



2. Résultats : quel modèle gagne ?

Métrique	Rég. logistique	Random Forest
Accuracy	0.58	0.60
Précision	0.49	0.51
Rappel (recall)	0.62	0.60
F1-score	0.55	0.55
AUC	0.64	0.65

Le **Random Forest** l'emporte de justesse (AUC 0.65 contre 0.64). Les deux modèles dépassent la référence naïve en accuracy (60% vs 57%) et surtout affichent une AUC nettement supérieure à 0,50 : ils captent un vrai signal. Restons lucides : **prédire le football reste difficile**, et c'est normal — l'aléa (un penalty, un carton rouge, un exploit individuel) est irréductible.




3. Lecture du meilleur modèle



La matrice de confusion montre où le modèle se trompe ; la courbe ROC (au-dessus de la diagonale du hasard) confirme son pouvoir discriminant.


4. Qu'est-ce qui compte le plus ?



Sans surprise mais de façon rassurante, les variables de **différence de forme** entre les deux équipes (écart de points et de buts récents) dominant : le modèle a appris que l'écart de dynamique entre les adversaires est plus parlant que la forme d'une seule équipe prise isolément.

5. Bonus non supervisé : les styles d'équipes (KMeans)

En complément de la prédiction, j'ai appliqué un **KMeans** pour regrouper les équipes selon leur profil moyen (buts marqués/encaissés, tirs, points...). Sans jamais lui donner le classement, l'algorithme retrouve **4 familles** cohérentes, des cadors aux équipes luttant pour le maintien — une validation visuelle que les données portent bien une structure.



6. Limites & honnêteté

- L'échantillon couvre une seule ligue (Premier League) et 5 saisons : la généralisation à d'autres championnats reste à vérifier.
- Le modèle ignore des facteurs réels (blessures, fatigue, calendrier européen, météo, compositions) faute de données — d'où un plafond de performance attendu.
- Prédire le football est intrinsèquement bruité : une AUC autour de 0,65 est un résultat honnête, pas une boule de cristal. Ce projet illustre une démarche rigoureuse, pas un système de paris.

Ce que ce projet démontre. Une chaîne complète et reproductible : collecte de données réelles, feature engineering sans fuite, comparaison de modèles supervisés, exploration non supervisée, sélection et export d'un modèle optimal prêt à prédire de nouveaux matchs — le tout avec un cadrage méthodologique transparent et des conclusions mesurées.