



C'est quoi un RAG ?

J'ai transformé mes fiches de révision en PDF en un assistant qui répond à mes questions... en citant la source exacte.

Python + NLP

100% local & privé

comprendre le RAG en 1 minute »



Une question simple, une réponse trop lente.

Le problème

Des dizaines de pages de fiches en PDF. Retrouver une notion précise comme le surapprentissage me prenait toujours trop de temps : Ctrl+F, scroll, et plusieurs fichiers à ouvrir.

L'idée

Et si je posais ma question en langage naturel, et qu'un programme fouillait tout seul mes documents pour me sortir LA bonne réponse, avec le fichier et la page ?



RAG = répondre en s'appuyant sur des documents.

RAG veut dire Retrieval-Augmented Generation. Au lieu de demander à une IA de répondre « de mémoire » (avec le risque qu'elle invente), on la branche sur des documents et on l'oblige à s'appuyer dessus.

IA seule

Répond de mémoire, peut inventer (halluciner), sans source vérifiable.

IA + RAG

Cherche d'abord dans tes documents, puis répond en citant la source exacte.



Le pipeline, en 4 étapes.

1 Extraction

On lit le texte de chaque PDF, page par page.

2 Découpage

On le coupe en petits passages (chunks).

3 Vectorisation

Chaque passage devient un vecteur : une empreinte de son sens.

4 Recherche

La question devient un vecteur ; on compare (similarité cosinus) et on remonte les passages les plus proches, avec leur source.



Le résultat, sans détour.



> c'est quoi le surapprentissage ?

[1] Fiche de revision - Data Science.pdf - page 4

k petit -> surapprentissage ; tester sur des donnees jamais vues...

- Le « retrieval » est le nerf de la guerre : mauvais passages = mauvaise réponse.
- Piège vaincu : les mots « c'est quoi » faisaient remonter toutes les FAQ. Les filtrer a tout changé.
- Tout tourne en local : mes données ne partent nulle part.

ET APRÈS ?



La moitié du chemin. L'autre arrive.

Pour l'instant, mon assistant renvoie les bons passages (le « Retrieval »). La suite logique : brancher un modèle de langage pour qu'il rédige la réponse en une phrase — c'est le « Generation » du RAG.

Ce que ça démontre

Comprendre et construire une brique concrète d'IA générative, de bout en bout, avec des outils simples et en local.

Sur quels documents brancheriez-vous un RAG ? »